CEFET/RJ

AVALIAÇÃO EXPERIMENTAL

Eduardo Ogasawara
eogasawara@ieee.org
https://eic.cefet-rj.br/~eogasawara

Experimentação

- Uso de experimentação para avaliar hipóteses é um dos pontos centrais da ciência
- Na computação é comum testar as implementações usando datasets
  - Confirmam hipóteses sobre algoritmos e sistemas
- Um teste de hipótese se torna parte do conhecimento científico se for suficiente bem concebido e demonstrado

[1] J. Zobel, 2015, *Writing for Computer Science*. Springer.

Referência para Comparação (baseline)

- A escolha do baseline é passo fundamental da concepção do experimento
- O baseline deve ser o estado da arte para resolução do problema
  - Exige conhecimento dos demais métodos e implementações antes mesmo de implementar a sua própria solução
  - É uma barreira de entrada para criação de novos métodos
- O baseline evolui com o tempo
  - A fixação de um baseline gera um ponto de referência
  - Técnicas melhores que ele podem não ser cumulativas
- Alguns algoritmos solucionam problemas novos
  - Usar o baseline mais lógico esperado para a solução

[1] J. Zobel, 2015, *Writing for Computer Science*. Springer.

Múltiplos Baselines

- Em alguns cenários complexos é necessário estabelecer baselines para diferentes abordagens para o problema

Neurocomputing

STConvS2S: Spatiotemporal Convolutional Sequence to Sequence Network for weather forecasting

Table 2
Performance results for temperature forecasting using the previous five observations (grids) to predict the next five observations (5 → 5), and the next 15 observations (5 → 15). We highlight the lowest values among the models.

Model	RMSE	MAE	Memory usage (MB)	Mean training time	Training time/epoch
	5 → 5				
ARIMA	2.1880	1.9005	–	–	–
ConvLSTM [19]	1.8555 ± 0.0033	1.2843 ± 0.0028	922	**02:38:27**	00:02:21
PredRNN [25]	1.6962 ± 0.0038	1.1885 ± 0.0020	2880	06:59:34	00:05:52
MIM [26]	1.6731 ± 0.0099	1.1790 ± 0.0055	4145	11:05:37	00:10:43
STConvS2S-C (ours)	1.3699 ± 0.0024	0.9434 ± 0.0020	1040	03:34:52	00:02:48
STConvS2S-R (ours)	**1.2692** ± 0.0031	**0.8552** ± 0.0018	**895**	03:15:12	**00:02:13**
	5 → 15				
Model	RMSE	MAE	Memory usage (MB)	Mean training time	Training time/epoch
ARIMA	2.2481	1.9077	–	–	–
ConvLSTM [19]	2.0728 ± 0.0069	1.4558 ± 0.0076	1810	5:29:30	00:07:32
PredRNN [25]	2.0237 ± 0.0067	1.4311 ± 0.0149	7415	11:45:48	00:17:03
MIM [26]	2.0287 ± 0.0361	1.4330 ± 0.0250	10673	19:19:00	00:31:19
STConvS2S-C (ours)	1.8739 ± 0.0107	1.2946 ± 0.0061	1457	**03:12:24**	00:05:17
STConvS2S-R (ours)	**1.8051** ± 0.0040	**1.2404** ± 0.0068	**1312**	03:15:42	**00:05:03**

[1] R. Castro, Y.M. Souto, E. Ogasawara, F. Porto, and E. Bezerra, 2020, STConvS2S: Spatiotemporal Convolutional Sequence to Sequence Network for weather forecasting, *Neurocomputing*, v. 426, p. 285–298.

Dados e Resultados

- Descreva conjunto de dados
  - Quais dados estão disponíveis?
  - Quais técnicas de preprocessamento foram utilizadas?
  - A quantidade de dados é suficiente?
  - Necessita de conhecimento de domínio?
  - Há limites, enviesamento, falhas nos dados?
    - Podem ser mitigados?
- Quais resultados corroboram para hipótese?
  - Como eles são quando a hipótese falha?
  - Há algum *gold standard* ou *ground truth*?

[1] J. Zobel, 2015, *Writing for Computer Science*. Springer.

Data papers

- Produzir os dados para conduzir o experimento é uma tarefa árdua para muitas áreas.
- Hoje em dia data papers estão sendo valorizados
- Sua disponibilização clarifica melhor os dados e dá a oportunidade para outros desenvolverem os seus métodos e algoritmos

Integrated Dataset of Brazilian Flights*

Claudio Teixeira[1], Lucas Giusti[1], Jorge Soares[1], José dos Santos[1], Glauco Amorim[1], Eduardo Ogasawara[1]

[1]CEFET/RJ - Federal Center for Technological Education of Rio de Janeiro

{claudio.teixeira,lucas.giusti}@eic.cefet-rj.br

{jorge.soares,jose.santos,glauco.amorim}@cefet-rj.br, eogasawara@ieee.org

Abstract. *The Brazilian commercial aviation system achieved the first position among Latin American countries and the fifteenth place worldwide on the Revenue Passenger-Kilometer ranking. The availability of flight information, including meteorological conditions, enables studies about the Brazilian flight system, such as flight delays and timetabling. Therefore, this paper contributes to such studies by offering an integrated dataset containing data on departure and arrival for flights departing and arriving at Brazilian airports comprising the period from 2000 to 2015. This paper presents a dataset composed of 15,505,922 records of flight data, each containing 43 attributes. The attributes include data regarding the airline, flight, airports, meteorological conditions, scheduled and elapsed times for departure and arrival.*

1. Introduction

The Brazilian commercial aviation system contains more than one hundred airports. It transported 95.9 million revenue passengers during 2014. It achieved the first position among Latin American countries and the fifteenth place worldwide on the Revenue Passenger-Kilometer (RPK) ranking [ICAO, 2015]. The commercial aviation network in Brazil is organized towards regional hubs in contrast to airline hubs. The main reason is the Brazilian territorial extension and that few Brazilian states have more than one major airport. One exception to this rule is Campinas (in the state of São Paulo), where airline company *Azul* holds 77% of its commercial flights. Besides, due to market deregulation instituted in 2005, the Brazilian commercial aviation system experienced significant changes in its players, leading to market share changes and flight availability.

The National Civil Aviation Agency (ANAC) regulates and supervises Brazilian civil aviation activities. Since 2000, ANAC keeps track of departure and arrival data for Brazilian flights in its Active Regular Flight (VRA) dataset [ANAC, 2015]. The data available in VRA are registered by the airlines and consolidated by ANAC. It contains data about each flight stage, i.e., the aircraft's necessary steps from its takeoff to the next landing. These steps are established regardless of where the object of transport has been loaded or unloaded. For each flight step, VRA provides data such as airline, flight number, type (such as international, domestic, and cargo), class (such as regular, extra, charter, and instruction), airports, and scheduled and elapsed times for departure and arrival. ANAC monthly provides VRA data on its website.

*The authors would like to thank CNPq, CAPES (finance code 001), and FAPERJ for the partial funding of the research.

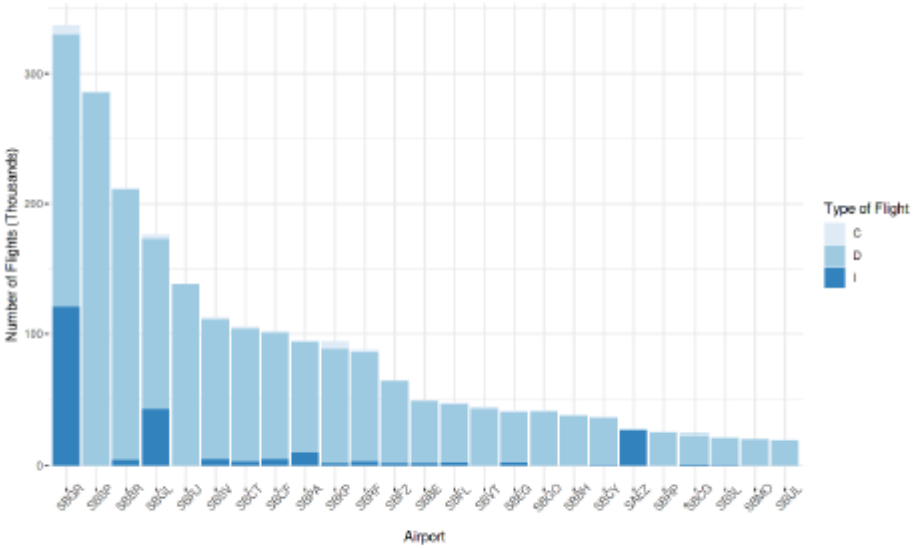

Figure 2. Number of flights per airport, for the top-25 most active airports

[1] C. Teixeira, L. Giusti, J. Soares, J. dos Santos, G. Amorim, and E. Ogasawara, 2021, Integrated Dataset of Brazilian Flights, In: *Anais do Brazilian e-Science Workshop (BreSci)*, p. 89–96

Interpretação

- Analise amplamente o resultado experimental
  - Todas as possíveis interpretações foram realizadas?
  - Testes adicionais conseguem descartar as demais interpretações?
- Atente quando as saídas negarem ou fizerem os experimentos falharem
  - Autor: “os resultados mostram que não é possível melhorar”
  - Avaliador: “eles não foram competentes”
- Analise os fatores que levaram ao resultado
  - Não adivinhe comportamento que não tenham resultados experimentais apoiando
  - Não tire conclusões equivocadas com os resultados

[1] J. Zobel, 2015, *Writing for Computer Science*. Springer.

Propriedades de boas avaliações experimentais

- Previsibilidade
  - Os experimentos devem trazer evidências de comportamento geral do sistema
    - Não apenas funcionar em conjunto de dados isolados
- Robustez
  - Os experimentos devem ser concebidos para prover resultados não ambíguos
    - Apresentar tendência e padrões de comportamento

[1] J. Zobel, 2015, *Writing for Computer Science*. Springer.

Tipos de avaliação experimental

- Processos automatizados (algoritmos, workflows)
  - Experimentações *in-silico*
  - Simulações
- Processos manuais
  - Avaliação com humanos
  - Questionários de avaliação
- Análise quantitativa e qualitativa

[1] J. Zobel, 2015, *Writing for Computer Science*. Springer.

Variável de resposta, parâmetros e fatores

- Variável de resposta
  - Saída do experimento (variável dependente)
  - O conjunto das saídas corresponde a uma observação
- Parâmetros
  - Alguma característica (qualitativa ou quantitativa) invariante ao longo do experimento
- Fatores
  - Características a variar
  - Variáveis de predição (independentes)

[1] J. Zobel, 2015, *Writing for Computer Science*. Springer.

Experimento elementar, replicação externa, erro experimental

- Experimento elementar
  - Cada execução em uma unidade experimental é denominada experimento unitário
- Replicações
  - Execuções sucessivas dos experimentos elementares
- Replicação externa
  - Desempenhada por pessoas externas (independentes)
  - Importante para garantir reprodutibilidade
- Erro experimental
  - Os resultados observados não são completamente idênticos
    - Processos estocásticos

[1] C. Alexopoulos, 2007, Statistical analysis of simulation output: State of the art, In: *Proceedings - Winter Simulation Conference*, p. 150–161
[2] A.M. Law, 2007, Statistical analysis of simulation output data: The practical state of the art, In: *Proceedings - Winter Simulation Conference*, p. 77–83

Projetando o experimento

- Identificar as variáveis de resposta, i.e., os produtos afetados pelos fatores/parâmetros
- Identificar os fatores (métodos e técnicas a serem estudados)
- Identificar os parâmetros
- Selecionar o tipo de experimento
  - Determinar o número de replicações
  - Seleção das amostras

[1] C. Alexopoulos, 2007, Statistical analysis of simulation output: State of the art, In: *Proceedings - Winter Simulation Conference*, p. 150–161
[2] A.M. Law, 2007, Statistical analysis of simulation output data: The practical state of the art, In: *Proceedings - Winter Simulation Conference*, p. 77–83

Como analisar experimentos automatizados

- O experimento foi projetado de modo que os dados gerados pudessem ser corretamente analisados?
- O que devo analisar?
- Quantas vezes preciso executar a simulação para realizar uma inferência?
- Devo descartar alguns elementos da saída do experimento?

Alexopoulos, C., (2007), "Statistical analysis of simulation output: State of the art". In: 2007 Winter Simulation Conference, p. 150–161
Law, A. M., (2007), "Statistical analysis of simulation output data: The practical state of the art". In: 2007 Winter Simulation Conference, p. 77–83

Período de aquecimento ("warm-up period")

- Descartam-se as primeiras t observações
- A identificação de t pode ser feita a partir de convergência de média ou técnica gráfica
- A análise dos resultados através de uma única execução pode gerar uma medição de variância subestimada
- A falha em separar o período de aquecimento pode afetar a análise
- O uso de técnica de repetição permite trazer precisão à saída de uma simulação
- A partir deste conceito pode-se calcular o intervalo de confiança

Alexopoulos, C., (2007), "Statistical analysis of simulation output: State of the art". In: 2007 Winter Simulation Conference, p. 150–161
Law, A. M., (2007), "Statistical analysis of simulation output data: The practical state of the art". In: 2007 Winter Simulation Conference, p. 77–83

Apresentando o resultado da avaliação experimental

- Avaliação experimental
  - Desmembrada em experimentos
- Procure deixar claros três pontos:
  - Objetivo do experimento
  - Dados utilizados
  - Resultados

[1] J. Zobel, 2015, *Writing for Computer Science*. Springer.

Ajustamento de modelo

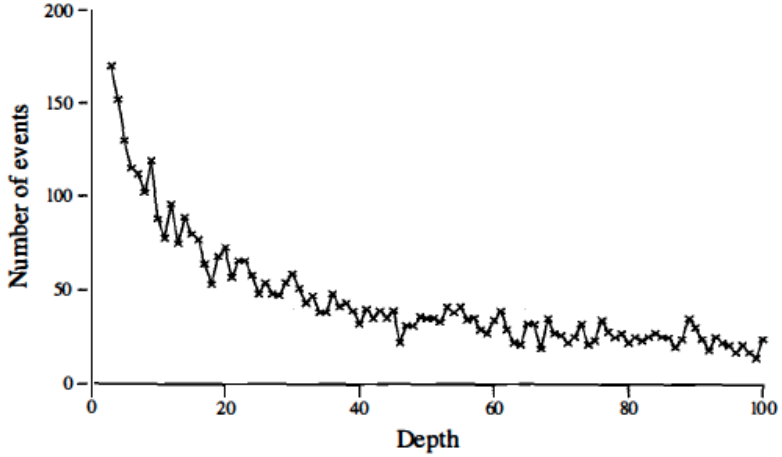

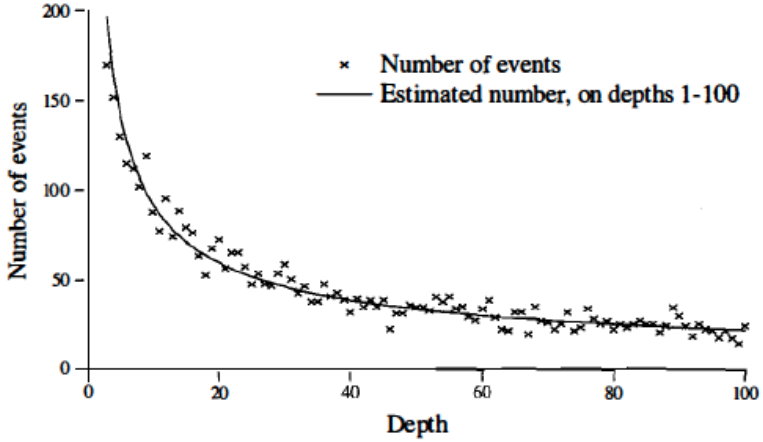

É um erro mostrar uma linha que interpola os pontos. Não tem em significado algum.

[1] J. Zobel, 2015, *Writing for Computer Science*. Springer.

Interpretação dos resultados pareados

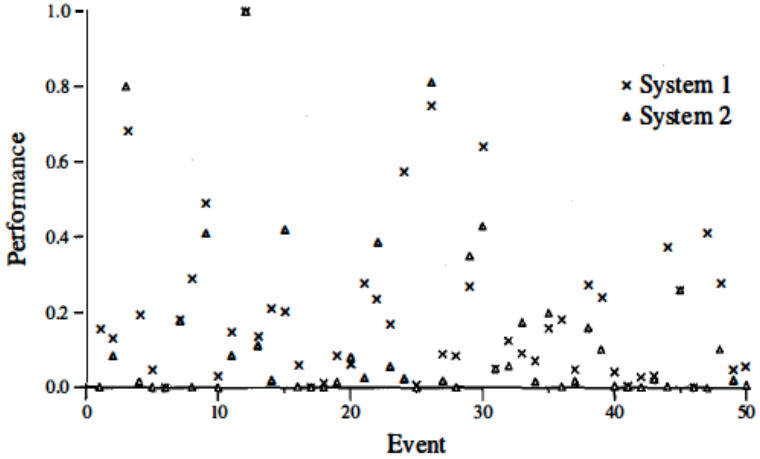

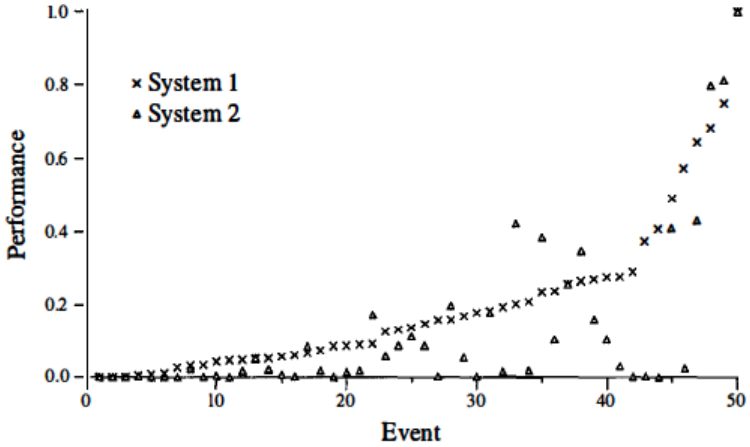

[1] J. Zobel, 2015, *Writing for Computer Science*. Springer.

Reprodutibilidade

- Mais de 70% dos cientistas tentaram e falharam ao reproduzir experimentos de outros autores
- Disponibilização de dados e código
- Uso de documentos ativos (Jupyter notebooks)
- Gerência de configuração
  - Obsolescência de código e plataforma

[1] C. Stoddart, 2016, Is there a reproducibility crisis in science?, *Nature* (May.)
[2] M. Baker, 2016, 1,500 scientists lift the lid on reproducibility, *Nature*, v. 533, n. 7604 (May.), p. 452–454.

Referências

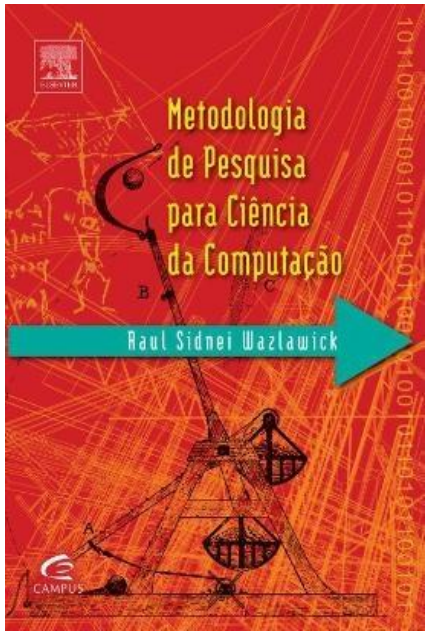

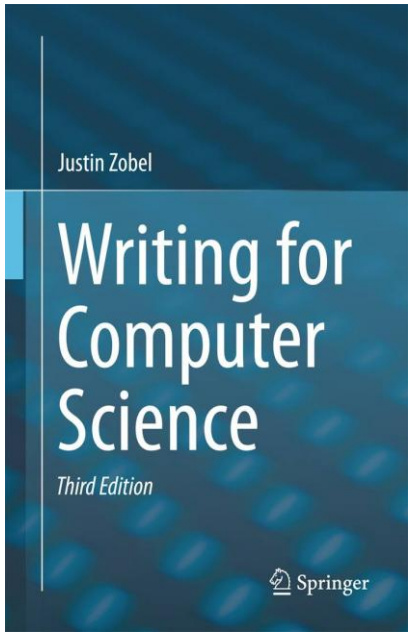

Leitura adicional Writing for Computer Science – Capítulos 14 e 15

Slides e vídeos em: https://eic.cefet-rj.br/~eogasawara/metodologia-cientifica/

[1] J. Zobel, 2015, *Writing for Computer Science*. Springer.
[2] R. Wazlawick, 2017, *Metodologia de Pesquisa para Ciência da Computação*. Elsevier Brasil.