



Elicit para Revisão de Literatura: Pergunta, Triagem e Critérios de Relevância

O que é o Elicit e para quem serve

O Elicit é uma ferramenta de assistente de pesquisa baseada em inteligência artificial, desenvolvida especificamente para pesquisadores acadêmicos, estudantes de pós-graduação e profissionais que precisam realizar revisões de literatura extensas e sistemáticas.

A plataforma foi desenhada para:

- Localizar artigos relevantes para sua pergunta de pesquisa
- Extrair informações específicas dos estudos encontrados
- Sistematizar e organizar o conhecimento científico
- Poupar tempo em processos mecânicos de busca bibliográfica

A interface do Elicit permite que você faça perguntas em linguagem natural e obtenha respostas baseadas em artigos científicos, acelerando significativamente o processo de revisão bibliográfica que tradicionalmente consumiria semanas de trabalho manual.

Cadastro e Interface do Elicit

Criação da conta

Acesse elicit.org e registre-se usando e-mail acadêmico ou conta Google. O plano básico é gratuito e oferece funcionalidades essenciais para pesquisadores individuais.

Painel principal

Após o login, você terá acesso ao painel central com suas pesquisas salvas e o histórico de consultas anteriores, facilitando a continuidade do seu trabalho.

Campo de pesquisa

O elemento central da interface é o campo "Ask a research question" onde você formulará sua pergunta de pesquisa em linguagem natural para iniciar a busca bibliográfica.

Formulando sua pergunta de pesquisa

A qualidade da sua revisão de literatura no Elicit depende fundamentalmente da formulação adequada da sua pergunta de pesquisa. Diferente de buscadores tradicionais, o Elicit permite o uso de linguagem natural completa.

Recomendações práticas:

- Seja específico sobre o que deseja descobrir, incluindo população, intervenção e resultados esperados
- Evite linguagem excessivamente técnica que possa limitar os resultados
- Reformule sua pergunta com base nos primeiros resultados para refinar sua busca
- Use termos alternativos para conceitos-chave quando necessário

Exemplo de pergunta bem formulada:

"Quais são os efeitos da meditação mindfulness na redução de sintomas de ansiedade em estudantes universitários, de acordo com estudos clínicos randomizados dos últimos 5 anos?"

Analizando os Resultados da Busca

Compreendendo a tabela de resultados

Após submeter sua pergunta, o Elicit apresenta uma tabela organizada com os artigos mais relevantes. Esta visualização inicial oferece um panorama do campo de estudo e permite:

- Verificar rapidamente títulos, autores e anos de publicação
- Identificar métodos de pesquisa utilizados
- Reconhecer padrões de publicação ao longo do tempo
- Verificar a distribuição de citações entre os trabalhos

Aplicando filtros eficientes

Para refinar seus resultados, utilize os filtros disponíveis:

- Recorte temporal (últimos 1-5 anos para revisões atualizadas)
- Metodologia de pesquisa (RCTs, meta-análises, estudos longitudinais)
- Relevância para sua pergunta específica
- Número de citações (impacto na literatura)

Lembre-se de que filtrar excessivamente pode eliminar estudos relevantes. Mantenha um equilíbrio entre precisão e abrangência.

Explorando os Artigos em Profundidade

A exploração detalhada dos artigos selecionados é fundamental para uma revisão de qualidade. O Elicit oferece diversas funcionalidades para facilitar esta análise:

- Visualização rápida de resumos e metodologias
- Destaque automático de trechos relevantes para sua pergunta
- Acesso direto aos PDFs quando disponíveis
- Ferramenta de marcação "Star" para priorizar artigos importantes

Utilize o botão "Show More" para expandir as informações disponíveis sobre cada artigo e obter uma compreensão mais completa do estudo em questão.

Dedique tempo especial aos artigos mais citados e às publicações mais recentes para equilibrar impacto e atualidade em sua revisão.

Fazendo Perguntas Específicas sobre os Artigos

Uma das funcionalidades mais poderosas do Elicit é a capacidade de fazer perguntas dirigidas sobre artigos específicos, o que permite extrair informações precisas sem necessidade de leitura integral de cada estudo.

Tipos de perguntas eficazes

- "Qual foi o tamanho da amostra neste estudo?"
- "Quais limitações os autores identificaram?"
- "Que instrumentos foram utilizados para medir a variável X?"
- "Quais foram os principais resultados estatísticos?"

Evidências destacadas

O Elicit fornece trechos do texto original como evidência para suas respostas, permitindo que você:

- Verifique a precisão da informação extraída
- Identifique citações potenciais para sua revisão
- Decida se precisa ler o artigo completo

Esta funcionalidade é particularmente útil na fase de triagem, quando você precisa determinar rapidamente quais artigos merecem uma análise mais aprofundada.

Exportando Dados para Seu Fluxo de Trabalho

Formatos de exportação disponíveis:



CSV

Ideal para análise quantitativa e manipulação em planilhas eletrônicas como Excel ou Google Sheets



BibTeX

Perfeito para integração com LaTeX e gerenciadores de referências como Overleaf



RIS


Formato universal compatível com a maioria dos gerenciadores de referências bibliográficas

Dicas para exportação eficiente:

- Exporte apenas os artigos que passaram por sua triagem inicial
- Verifique os metadados para garantir precisão das referências
- Para Zotero ou EndNote, prefira o formato RIS para maior compatibilidade
- Documente o processo de exportação para replicabilidade

Conduzindo Revisões Sistemáticas com o Elicit

O Elicit pode ser incorporado ao fluxo de trabalho de revisões sistemáticas, trazendo maior eficiência sem comprometer o rigor metodológico necessário.



Síntese e Exportação de Resultados

Estratégias de síntese eficiente:

1. **Organização temática:** Agrupe evidências por temas recorrentes identificados nos artigos
2. **Comparação metodológica:** Compare resultados de estudos com metodologias similares para identificar consistências
3. **Análise cronológica:** Observe a evolução das descobertas ao longo do tempo
4. **Identificação de lacunas:** Utilize a visão panorâmica oferecida pelo Elicit para identificar áreas pouco estudadas

Utilize os rascunhos gerados pelo Elicit como ponto de partida para sua escrita, mas sempre acrescente sua análise crítica e contextualização teórica para enriquecer o trabalho final.

A síntese qualitativa dos achados é facilitada pelas funcionalidades de agrupamento do Elicit, que permitem identificar padrões e tendências na literatura.

❏ **Dica:** Mantenha um registro claro das perguntas utilizadas no Elicit e dos filtros aplicados para garantir que sua metodologia seja reproduzível - elemento essencial de qualquer revisão sistemática de qualidade.

Mantendo sua Revisão de Literatura Atualizada

Estratégias de atualização contínua:

Uma revisão de literatura de qualidade não é um produto estático, mas um documento vivo que deve ser atualizado regularmente. O Elicit facilita este processo através de:

- Salvamento de fluxos de trabalho para reutilização
- Preservação de critérios de inclusão/exclusão
- Comparação facilitada entre resultados antigos e novos
- Acompanhamento de tendências emergentes

Esta prática é especialmente importante para pesquisas em campos que evoluem rapidamente, onde novas publicações podem alterar significativamente o panorama científico em questão de meses.

Documentando atualizações:

Para manter o rigor metodológico, é essencial documentar:

- Data de cada atualização realizada
- Novas perguntas incorporadas à revisão
- Modificações nos critérios de busca
- Justificativa para inclusão/exclusão de novos estudos

Formulando Perguntas de Pesquisa Eficazes para o Elicit

A qualidade dos resultados obtidos no Elicit depende diretamente da formulação adequada de suas perguntas de pesquisa. Uma estratégia eficaz consiste em transformar introduções conceituais em perguntas objetivas e estruturadas.

Fluxo recomendado:

Introdução

Texto explicativo sobre seu tema de pesquisa

ChatGPT

Estruturação da pergunta com metodologia PICOC

Pergunta

Consulta objetiva e estruturada

Elicit

Resultados mais precisos e relevantes

Este fluxo integrado permite aproveitar o melhor das ferramentas de IA disponíveis, utilizando o ChatGPT para estruturar perguntas e o Elicit para realizar buscas especializadas na literatura científica.

Por que nem toda pergunta funciona bem no Elicit?

Perguntas vagas

Perguntas genéricas como "O que se sabe sobre marketing digital?" produzem resultados dispersos e superficiais, sem foco em aspectos específicos que realmente interessam à sua pesquisa.

A ferramenta precisa de direcionamento claro para filtrar a vasta literatura disponível.

Trechos excessivamente longos

Introduzir parágrafos inteiros ou textos muito extensos confunde o algoritmo do Elicit, que pode se perder entre múltiplos conceitos e relações.

A objetividade é essencial para resultados precisos.

O equilíbrio ideal

Perguntas eficazes encontram um ponto intermediário: específicas o suficiente para direcionar a busca, mas não tão restritivas a ponto de eliminar estudos relevantes.


A metodologia PICOC ajuda a encontrar este equilíbrio.

Metodologia PICOC: Estruturando Perguntas Eficazes

A metodologia PICOC estende a estrutura PICO, de origem clínica, com o elemento Context (C). Foi proposta por Petticrew e Roberts (2006) para revisões nas ciências sociais e adotada na Engenharia de Software pelas diretrizes de revisão sistemática de Kitchenham e Charters (2007). O Contexto explicita o ambiente em que os estudos ocorrem, o que a torna adequada para formular perguntas de pesquisa em Computação no Elicit.

Population (P)
Quem ou o que está sendo estudado? Qual é o grupo, configuração ou cenário específico da pesquisa?
Ex.: desenvolvedores de software, equipes ágeis, sistemas embarcados

Context (C)
Qual é o ambiente, cenário experimental ou condição em que a pesquisa ocorre? Elemento que explicita o ambiente ou cenário dos estudos.
Ex.: ambiente industrial, projeto acadêmico, sistema legado, startup



Intervention (I)

Qual é o principal fator, intervenção, técnica ou abordagem sendo investigada?

Ex.: Test-Driven Development, integração contínua, machine learning

Comparison (C)

Existe um método alternativo, abordagem controle ou situação comparativa relevante?

Ex.: comparado com desenvolvimento tradicional, em relação a métodos manuais

Outcome (O)

Quais são os resultados ou efeitos específicos de interesse na pesquisa?

Ex.: redução de defeitos, aumento de produtividade, melhora na manutenibilidade

Exemplo Prático: Engenharia de Software com PICOC

A metodologia PICOC é uma ferramenta poderosa para estruturar perguntas de pesquisa claras e objetivas em Engenharia de Software. Vejamos como aplicá-la na comparação entre Test-Driven Development (TDD) e abordagens tradicionais de teste no impacto sobre a qualidade do código em projetos de software empresarial.

P – População

Equipes de desenvolvimento de software em projetos empresariais de médio a grande porte (≥ 10 desenvolvedores)

I – Intervenção

Test-Driven Development (TDD) — prática em que os testes são escritos antes do código de produção

C – Comparação

Abordagens tradicionais de teste (testes escritos após o desenvolvimento, sem cobertura sistemática)

O – Outcome

Densidade de defeitos, cobertura de código, tempo de correção de bugs e manutenibilidade do código

C – Context

Projetos de software corporativo com ciclos de entrega contínua (CI/CD) e equipes distribuídas geograficamente

Pergunta resultante (PICOC): "Como o Test-Driven Development (TDD) se compara às abordagens tradicionais de teste na qualidade do código produzido por equipes de desenvolvimento em projetos empresariais de médio a grande porte, considerando densidade de defeitos, cobertura de código, tempo de correção de bugs e manutenibilidade, em contextos de entrega contínua com equipes distribuídas geograficamente?"

Dica de uso no Elicit

Utilize esta pergunta PICOC completa diretamente no Elicit para encontrar experimentos controlados, estudos de caso e revisões sistemáticas sobre TDD em contextos industriais. O Elicit irá destacar evidências empíricas sobre o impacto real do TDD na qualidade do código, ajudando você a identificar o estado da arte e as lacunas de pesquisa mais relevantes para projetos de grande escala.

O Processo de Formulação com ChatGPT

O uso estratégico do ChatGPT pode transformar suas ideias iniciais de pesquisa em perguntas estruturadas e prontas para o Elicit. Este processo sistemático garante que você maximize a relevância dos resultados obtidos.

Fornecer a introdução

Compartilhe com o ChatGPT um parágrafo descrevendo seu tema de pesquisa, incluindo contexto, problema e objetivos gerais. Quanto mais detalhado e específico você for, melhor será o resultado obtido.

Extração do PICOC

O ChatGPT analisa seu texto e identifica os cinco elementos estruturais: População, Intervenção, Comparação, Outcome e Contexto, organizando-os de forma sistemática e clara.

Formulação da pergunta

Com base nos elementos PICOC identificados, o ChatGPT formula uma pergunta clara, concisa e bem estruturada, pronta para ser utilizada diretamente no Elicit.

Refinamento iterativo

Se necessário, você pode solicitar ajustes na pergunta gerada, pedindo versões alternativas ou enfatizando aspectos específicos do seu interesse de pesquisa até alcançar a formulação ideal.

Benefícios da Metodologia PICOC

Vantagens Metodológicas

- Maior rigor científico na formulação de perguntas em qualquer área da Computação
- Clareza conceitual que facilita a comunicação entre pesquisadores da área de Computação
- Reprodutibilidade melhorada do processo de revisão sistemática de literatura
- Documentação sistemática da evolução da pergunta de pesquisa
- Manutenção de um registro histórico de perguntas para análise e refinamento futuro

Vantagens Práticas

- Perguntas mais diretas e específicas para o Elicit processar com eficiência
- Resultados mais relevantes e focados no interesse real da pesquisa em Computação e áreas afins
- O elemento **Context** torna o PICOC especialmente adequado para pesquisas em ambientes técnicos e científicos específicos
- Economia significativa de tempo durante o processo de revisão sistemática
- Redução da sobrecarga cognitiva ao avaliar grandes volumes de artigos científicos

❏ A estruturação PICOC é um framework amplamente adotado em revisões sistemáticas nas áreas de Computação, Ciência de Dados, Inteligência Artificial e afins (Kitchenham e Charters, 2007). O elemento Context permite não apenas melhorar os resultados imediatos, mas também construir um processo de pesquisa sistemático adaptado ao contexto computacional, gerando aprendizado institucional contínuo.

Exemplo Completo: Classificação do Dataset Iris com PICOC

O dataset Iris é um dos mais conhecidos em aprendizado de máquina, tornando-o ideal para ilustrar a aplicação completa do PICOC. Veja como transformar uma ideia de pesquisa em uma pergunta estruturada pronta para o Elicit.

P – População

Dataset Iris (150 amostras de flores com 4 atributos: comprimento e largura de sépalas e pétalas, 3 classes: Setosa, Versicolor, Virginica)

I – Intervenção

Redes Neurais Profundas (Deep Learning) — especificamente Multilayer Perceptron (MLP) aplicado ao dataset Iris

C – Comparação

Métodos clássicos de aprendizado de máquina (K-Nearest Neighbors, Naive Bayes, Decision Tree, Random Forest, SVM)

O – Outcome

Acurácia, F1-score, tempo de treinamento e interpretabilidade do modelo

C – Context

Ambiente de aprendizado acadêmico com dataset balanceado, sem ruído e de baixa dimensionalidade

Pergunta resultante (PICOC): "Como redes neurais profundas (MLP) se comparam aos métodos clássicos de aprendizado de máquina (KNN, Naive Bayes, Decision Tree, Random Forest e SVM) na classificação de espécies do dataset Iris, considerando acurácia, F1-score, tempo de treinamento e interpretabilidade do modelo, em um ambiente acadêmico com dataset balanceado, sem ruído e de baixa dimensionalidade?"

Executando a Pesquisa no Elicit

Criando Colunas de Relevância Personalizadas

O Elicit permite criar colunas customizadas que transformam critérios subjetivos de relevância em parâmetros objetivos de avaliação, facilitando dramaticamente a filtragem sistemática de artigos sobre classificação de espécies com algoritmos de ML no dataset Iris e outros temas complexos.

Ao definir claramente os critérios de inclusão e exclusão antes de iniciar sua análise, você consegue:



Identificar rapidamente estudos que comparam MLP com métodos clássicos de ML no dataset Iris

Como KNN, SVM, Decision Trees e outras variantes relevantes para seu contexto de pesquisa



Filtrar por tipo de algoritmo e métricas de avaliação (acurácia, F1-score, interpretabilidade)

Garantindo que os estudos analisados correspondam ao escopo metodológico e às métricas de interesse



Avaliar a aplicabilidade dos achados para datasets balanceados de baixa dimensionalidade

Determinando se os resultados podem ser generalizados para seu contexto específico de pesquisa

Passo 1 – Criando a Coluna de Relevância

Acessar a tabela de resultados

Após realizar sua busca inicial sobre classificação do dataset Iris com MLP e métodos clássicos no Elicit, localize a tabela de resultados com os artigos encontrados pela plataforma.

Clicar em "Add column"

Este botão geralmente aparece no canto superior direito da tabela de resultados ou ao final das colunas existentes, dependendo do layout da interface.

Nomear a coluna adequadamente

Escolha um nome descritivo e específico como "Relevância para classificação Iris" ou "Comparação MLP vs. clássicos", dependendo do seu foco específico de pesquisa.

 **Dica importante:** Use nomes de colunas que façam sentido não apenas para você, mas também para outros membros da sua equipe de pesquisa. A clareza na nomenclatura facilita a colaboração e a reprodutibilidade do trabalho.

Passo 2 – Descrevendo a Coluna Eficazmente

Utilizando o Campo "Description"

Este campo deve conter uma explicação sucinta, porém completa, do propósito da coluna e dos critérios que serão aplicados durante a avaliação dos artigos.

Exemplo de Descrição Eficaz:

"Esta coluna avalia se o artigo apresenta comparações empíricas entre redes neurais profundas (MLP) e métodos clássicos de aprendizado de máquina (KNN, SVM, Decision Tree) aplicados ao dataset Iris ou datasets similares de baixa dimensionalidade, com foco em métricas de acurácia e interpretabilidade."

Uma descrição bem elaborada serve múltiplos propósitos essenciais: ajuda outros pesquisadores a compreenderem sua metodologia e lógica de classificação, facilita seu próprio processo de revisão sistemática ao manter a consistência ao longo do tempo, e permite que você retome o trabalho após interrupções sem perder o fio da meada.

- ❏ Considere incluir na descrição exemplos específicos de metodologias ou tipos de estudos que você considera relevantes. Isso aumenta significativamente a consistência na aplicação dos critérios.

Passo 3 – Definindo Instruções Precisas

Com a descrição da coluna definida no passo anterior, o próximo elemento essencial são as instruções para cada categoria de classificação. A definição clara de critérios para cada categoria de relevância é fundamental para garantir consistência na avaliação de múltiplos artigos ao longo do tempo.

Os exemplos abaixo utilizam o tema de **classificação com MLP vs. métodos clássicos no dataset Iris** como referência ilustrativa — adapte os critérios ao seu próprio tema de pesquisa conforme necessário.

SIM (Yes)

O artigo apresenta comparação empírica direta entre MLP (ou redes neurais) e métodos clássicos de ML (KNN, SVM, Decision Tree, Random Forest) aplicados ao dataset Iris ou datasets de classificação de baixa dimensionalidade, com métricas de acurácia e/ou F1-score reportadas.

TALVEZ (Maybe)

O artigo aborda MLP ou métodos clássicos de ML em problemas de classificação, mas não usa o dataset Iris especificamente; ou compara apenas alguns dos algoritmos de interesse; ou foca em aspectos tangenciais como otimização de hiperparâmetros sem comparação direta.

NÃO (No)

O artigo não trata de classificação com ML, ou aborda apenas deep learning em problemas de alta dimensionalidade (imagens, NLP), sem relação com datasets tabulares simples como o Iris.

As instruções devem ser detalhadas o suficiente para permitir classificação consistente e reproduzível entre diferentes avaliadores, mas simultaneamente concisas para facilitar a aplicação rápida durante a revisão de múltiplos artigos sem causar fadiga cognitiva.

Com os critérios bem definidos, o próximo passo é salvar esta configuração como preset para reutilização futura.

Passo 4 – Salvando como Preset para Uso Futuro

Após configurar cuidadosamente sua coluna de relevância para classificação com MLP vs. métodos clássicos no dataset Iris, é fundamental salvá-la como preset para uso em pesquisas futuras e garantir consistência metodológica.

Acessar o menu da coluna

Clique na seta para baixo (▼) localizada ao lado do nome da coluna recém-criada para abrir o menu de opções

Selecionar "Save as preset"

Escolha a opção "Save as preset" no menu dropdown que aparece para iniciar o processo de salvamento

Nomear o preset

Confirme o nome do preset ou ajuste conforme necessário para facilitar identificação futura

Adicionar tags descritivas

Inclua tags relacionadas como "dataset Iris", "classificação ML", "MLP vs. clássicos", "aprendizado de máquina" para facilitar a busca e organização

 **Benefício colaborativo:** Presets podem ser compartilhados com outros pesquisadores do seu grupo de pesquisa, criando um padrão metodológico consistente para toda a equipe e facilitando a integração de novos membros em projetos em andamento.

Este procedimento economiza tempo significativo em projetos de pesquisa subsequentes e garante consistência metodológica entre diferentes estudos realizados ao longo dos meses ou anos.

Passo 5 – Aplicando e Refinando a Metodologia

1. Aplicação Inicial

Use a coluna para classificar os primeiros 10-15 artigos da sua pesquisa sobre classificação no dataset Iris, observando cuidadosamente a distribuição entre as categorias "Sim", "Não" e "Talvez".

3. Ajuste dos Critérios

Refine as instruções se necessário, tornando-as mais específicas para capturar nuances importantes da comparação entre MLP e métodos clássicos de ML em seu contexto particular de estudo com o dataset Iris.

2. Avaliação da Eficácia

Verifique se os critérios estão separando adequadamente os artigos relevantes dos não relevantes para sua pesquisa sobre MLP vs. métodos clássicos de ML, analisando possíveis inconsistências.

4. Aplicação Completa

Classifique todos os artigos restantes e utilize os resultados para embasar sua revisão de literatura e desenvolvimento metodológico subsequente sobre classificação no dataset Iris.

Monitoramento de Qualidade

À medida que classifica mais artigos, monitore a consistência de suas classificações. Se notar muitos artigos na categoria "Talvez", considere tornar seus critérios mais específicos para a comparação entre MLP e métodos clássicos de ML.

Documentação do Processo

Mantenha um registro das modificações feitas nos critérios ao longo do processo. Esta documentação será valiosa para a seção de métodos da sua pesquisa.


Conclusão: A metodologia apresentada neste tutorial, quando aplicada sistematicamente, transforma o Elicit em uma ferramenta poderosa para revisões de literatura rigorosas e eficientes, economizando dezenas de horas de trabalho enquanto aumenta a qualidade metodológica da sua pesquisa acadêmica.

Referências Bibliográficas




Perovano (2016)

**Manual de metodologia da
pesquisa científica** - Editora
Intersaberes.




Cervo, Bervian & Silva
(2006)

Metodologia Científica -
Pearson Universidades.



Wazlawick (2017)

**Metodologia de Pesquisa para
Ciência da Computação** -
Elsevier Brasil.



Zobel (2015)

Writing for Computer Science
— Springer.

- **Wohlin et al. (2012)** — *Experimentation in Software Engineering* — Springer. ISBN 978-3-642-29043-5.
- **Petticrew & Roberts (2006)** — *Systematic Reviews in the Social Sciences: A Practical Guide* — Blackwell.
- **Kitchenham & Charters (2007)** — *Guidelines for Performing Systematic Literature Reviews in Software Engineering* — Technical Report EBSE-2007-01, Keele University and Durham University.